

Structured Knowledge-Enhanced Retrieval for Financial Documents

Đề tài nghiên cứu: Truy xuất tài liệu tài chính tăng cường tri thức cấu trúc

Abstract

Truy xuất ngữ cảnh chính xác từ các báo cáo tài chính, vốn luôn tồn tại dưới dạng hỗn hợp giữa văn bản tự sự và bảng biểu, là một bước ngoặt then chốt quyết định hiệu năng của các hệ thống Retrieval-Augmented Generation (RAG) trong lĩnh vực tài chính. Khảo sát cho thấy các phương pháp truy xuất dày (dense retrieval) hiện hành thường gặp thất bại nghiêm trọng trên miền dữ liệu này. Nguyên nhân chính bắt nguồn từ việc chúng xử lý các bảng biểu giống như văn bản phẳng (flat text), qua đó vô tình phá hủy đi các ràng buộc toán học nội tại, đồng thời bỏ qua tính phân biệt cực kỳ quan trọng của siêu dữ liệu thực thể. Trong nghiên cứu này, chúng tôi đề xuất **GSR** (Graph-Structured Retrieval) – một khung truy xuất biểu diễn bảng tài chính dưới dạng Đồ thị Tri thức. Các cạnh của đồ thị này biểu diễn trực tiếp các ràng buộc kế toán có hướng (Constraint KG). Đồ thị này sau đó được xử lý thông qua mạng GAT nhận biết cạnh (Edge-Aware GAT) và kết hợp với điểm số vi phạm ràng buộc (Constraint Score) để đánh giá tài liệu một cách toàn diện. Hơn thế nữa, nhằm mục đích tối ưu hóa quá trình huấn luyện, chúng tôi phát triển **CACL** (Constraint-Aware Contrastive Learning), kết hợp với kỹ thuật sinh mẫu âm khó mang tên **CHAP**. Kỹ thuật này hoạt động dựa trên nguyên lý phá vỡ có chủ đích các đẳng thức kế toán để tạo ra các mẫu âm khó mang tính thách thức cao. Thử nghiệm quy mô lớn trên benchmark T²-RAGBench (bao gồm FinQA, ConvFinQA, TAT-DQA) cho thấy phương pháp đề xuất vượt trội đáng kể (+13.1% MRR@3 trên FinQA) so với các baselines mạnh nhất hiện nay, ngay cả khi không sử dụng bất kỳ Mô hình Ngôn ngữ Lớn (LLM) nào trong pha truy xuất.

1 Giới thiệu (Introduction)

Sự bùng nổ của các mô hình ngôn ngữ lớn đã thúc đẩy mạnh mẽ ứng dụng của các hệ thống hỏi đáp (QA) và sinh văn bản tăng cường truy xuất (RAG) vào nhiều lĩnh vực chuyên sâu. Trong lĩnh vực tài chính, cốt lõi để một hệ thống RAG hoạt động hiệu quả là khả năng truy xuất tự động và chính xác các ngữ cảnh từ kho báo cáo khổng lồ. Đặc thù của tài liệu tài chính khác hoàn toàn so với các tài liệu mở (open-domain) thông thường: chúng được cấu trúc rất chặt chẽ, bao gồm văn bản tự sự (narratives) giải thích tình hình kinh doanh, siêu dữ liệu thực thể (metadata như tên công ty, năm tài chính, lĩnh vực) và đặc biệt là các bảng biểu định dạng đậm đặc các con số (dense tables) tuân theo các chuẩn mực báo cáo IFRS hoặc GAAP.

Mặc dù các mô hình truy xuất dày (dense retrieval) dựa trên kiến trúc bi-encoder (chẳng hạn như DPR hay BGE) đã đạt được hiệu năng ấn tượng trên các miền dữ liệu chung, chúng vẫn liên tục gặp giới hạn khi đối mặt với sự phức tạp của tài liệu tài chính. Vấn đề nghiêm trọng và phổ biến nhất được ghi nhận là hiện tượng "ảo giác trùng lặp từ vựng" (lexical overlap illusion). Cụ thể, các báo cáo tài chính của cùng một công ty qua nhiều năm thường sử dụng lại một lượng lớn cấu trúc câu và từ vựng. Sự lặp lại ngữ pháp này khiến cho các mô hình truy xuất tiêu chuẩn bị nhầm lẫn, dẫn đến việc gán điểm tương đồng cao cho các tài liệu sai thời điểm hoặc sai công ty, gây ra hiện tượng Nhầm lẫn Thực thể (Entity Conflation). Tệ hơn nữa, để xử lý các bảng số liệu, các mô hình này buộc phải "làm phẳng" (flattening) chúng thành chuỗi văn bản (ví dụ như chuỗi markdown). Hành động này vô hình trung phá hủy đi mối quan hệ phân cấp (cha-con) giữa các hàng, cột, cũng như làm bay hơi các nguyên tắc kế toán bất biến (như Doanh thu - Giá vốn = Lợi nhuận gộp). Hậu quả là mô hình hoàn toàn mất đi khả năng nhận thức logic toán học, dễ dàng bị đánh lừa bởi những tài liệu có chứa các con số trông có vẻ liên quan nhưng lại vi phạm cấu trúc tính toán.

Để khắc phục những giới hạn cốt lõi trên, nghiên cứu này đề xuất **GSR** (Graph-Structured Retrieval). Khác với các phương pháp trước đây, GSR mở rộng không gian biểu diễn bằng cách tích hợp hai luồng thông tin đặc thù của miền tài chính. Thứ nhất, siêu dữ liệu thực thể được mô hình hóa một cách tường minh thông qua học đối lập có giám sát (Supervised Contrastive Learning) nhằm nâng cao năng lực phân biệt thực thể. Thứ hai, thay vì làm phẳng bảng, GSR duy trì toàn vẹn cấu trúc bằng cách trích xuất chúng thành các Đồ thị Tri thức Ràng buộc (Constraint Knowledge Graph), trong đó mỗi ô dữ liệu là một node, và các cạnh biểu diễn các công thức kế toán. Cấu trúc đồ thị này được xử lý bằng mạng Graph Attention Network nhận biết cạnh (Edge-Aware GAT) chuyên biệt, giúp mô hình tự động kiểm tra tính hợp lệ của số liệu và tạo ra điểm số Constraint Score để sàng lọc tài liệu chính xác hơn.

Thêm vào đó, để cung cấp môi trường học tập tối ưu cho mô hình, chúng tôi đề xuất **CACL** (Constraint-Aware Contrastive Learning). Vấn đề lớn trong học đối lập là thiếu hụt các mẫu âm chất lượng cao. CACL giải quyết điều này bằng **CHAP** – một kỹ thuật sinh mẫu âm khó dựa trên việc cố tình tạo ra các vi phạm vi mô trong báo cáo tài chính (chẳng hạn như thay đổi giá trị một ô tính, hoặc hoán đổi công ty). Việc bị ép buộc phải phân biệt giữa tài liệu gốc và tài liệu vi phạm CHAP giúp hệ thống thực sự học được ”ngữ nghĩa ràng buộc toán học” thay vì chỉ học vẹt các biểu diễn bề mặt.

Tóm tắt các đóng góp chính của nghiên cứu:

- Chúng tôi đóng góp một khung phân tích lý thuyết sắc bén, sử dụng lý thuyết thông tin để hệ thống hóa nguyên nhân thất bại của dense retrieval trên tài liệu tài chính (Entity Conflation và Mathematical Flattening).
- Đề xuất khung kiến trúc **GSR** tích hợp đồ thị Constraint KG, Edge-Aware GAT và Joint Scorer, lần đầu tiên cho phép nhúng trực tiếp các ràng buộc toán học vào không gian truy xuất.
- Thiết kế phương pháp huấn luyện **CACL** với kỹ thuật sinh mẫu âm **CHAP**, mở ra hướng đi mới trong việc đào tạo mô hình bằng mẫu âm dựa trên vi phạm logic thay vì vi phạm ngữ nghĩa đơn thuần.
- Đạt kết quả SOTA vững chắc trên các tập dữ liệu FinQA, ConvFinQA, và TAT-DQA, chứng minh ưu thế của mô hình cấu trúc so với các phương pháp lai hoặc các phương pháp dùng LLM khổng lồ.

2 Công trình liên quan (Related Work)

Truy xuất bảng trong tài liệu tài chính. Gần đây, việc truy xuất từ các tài liệu hỗn hợp đa phương thức đã thu hút sự quan tâm lớn. HELIOS [2] tiếp cận bằng cách sử dụng đồ thị hai phía (bipartite graph) để tạo mối liên kết giữa các bảng và các đoạn văn bản xung quanh, nhằm giải quyết các truy vấn đa bước. Dù vậy, phương pháp này bỏ ngỏ hoàn toàn các ràng buộc kế toán nằm bên trong chính các bảng. THYME [3] và THoRR [4] đề xuất các phương pháp ghép nối theo trường (field-aware) và truy xuất chia làm hai giai đoạn chủ yếu dựa trên thông tin header của bảng. Tuy nhiên, các kỹ thuật này vẫn chỉ xử lý thông tin ở cấp độ ghép nối bề mặt từ vựng, thiếu hụt đi một sự thấu hiểu toàn cục về sự ràng buộc của các con số. Trái ngược lại, hệ thống GSR của chúng tôi phân tích sâu hơn bằng cách trích xuất trực tiếp logic kế toán thành các đồ thị có hướng.

Học đối lập và Khai thác Mẫu âm khó. Hiệu năng của các mô hình dense retrieval phụ thuộc mang tính sống còn vào chất lượng của tập mẫu âm (negative samples). DPR [6] thiết lập một tiêu chuẩn chuẩn mực bằng cách sử dụng BM25 để tìm ra các mẫu âm khó (hard negatives) mà mô hình vector dễ dự đoán sai. Trong những nghiên cứu gần đây, ConFIT [5] đã chứng minh được lợi ích vượt trội của việc tạo mẫu âm nhân tạo thông qua việc nhiễu ngữ nghĩa dựa trên các từ điển tri thức như Wikidata. Tuy nhiên, trong lĩnh vực tài chính chuyên biệt, chưa có nghiên cứu nào tận dụng chính các phương trình toán học nội tại của các báo cáo để tạo ra mẫu âm một cách tinh tế. Phương pháp CHAP lấp đầy khoảng trống này bằng việc biến đổi các công thức thành các mẫu âm khó mang tính đánh lừa cao.

3 Nền tảng Lý thuyết và Động lực Nghiên cứu

Tài liệu trong miền tài chính mang một sự pha trộn đặc biệt giữa văn bản (text) và bảng biểu (tables). Việc áp dụng một cách khiên cưỡng các phương pháp truy xuất tiêu chuẩn đã làm bộc lộ hai khiếm khuyết cốt lõi về mặt lý thuyết, từ đó định hình nên động lực cho nghiên cứu này.

3.1 Hiện tượng Nhầm lẫn Thực thể (Entity Conflation) do Trùng lặp Từ vựng

Theo góc nhìn ngôn ngữ học chức năng, đặc trưng của văn bản báo cáo tài chính – vốn chịu sự chi phối nghiêm ngặt của các chuẩn mực như IFRS hay GAAP – là tính khuôn mẫu cực kỳ cao (Formulaic Encoding [8]). Hệ quả là, các báo cáo tài chính của cùng một công ty qua nhiều năm liên tiếp, hoặc của các công ty đối thủ trong cùng một ngành công nghiệp, thường tái sử dụng lại đến 80-90% cấu trúc câu và kho từ vựng.

Khi các tài liệu này được biểu diễn dưới dạng vector thông qua các mô hình bi-encoder truyền thống, sự tương đồng áp đảo về từ vựng (lexical) sẽ che lấp đi sự khác biệt mang tính quyết định về các thông tin thực thể (siêu dữ liệu như năm, tên công ty, ngành nghề). Tình trạng này khiến cho các mô hình truy xuất bị rơi vào hiện

tượng "Ảo giác trùng lặp từ vựng" (Lexical Overlap Illusion), trong đó mô hình chấm điểm tương đồng rất cao cho các tài liệu sai thời điểm hay sai đối tượng, chỉ vì chúng chia sẻ chung một cấu trúc ngữ pháp.

3.2 Sự phá hủy Cấu trúc Toán học khi Làm phẳng Bảng (Mathematical Flattening)

Để đưa bảng biểu vào các mô hình transformer, phương pháp thông thường là tuyến tính hóa (làm phẳng) bảng thành chuỗi markdown hoặc chuỗi văn bản liền mạch. Dưới góc nhìn của Lý thuyết Thông tin [9], tổng lượng thông tin biểu diễn $H(T)$ của một bảng tài chính T có thể được phân tách thành:

$$H(T) = H_{\text{Text}}(T) + H_{\text{Structure}}(T) + H_{\text{Numbers}}(T) \quad (1)$$

Trong công thức này, $H_{\text{Structure}}(T)$ nắm giữ lượng thông tin vô giá liên quan đến các ràng buộc toán học và logic phân cấp (cha-con, hàng-cột). Khi thực hiện việc tuyến tính hóa, mô hình buộc phải chịu một lượng mất mát thông tin I_{loss} có thể xấp xỉ bằng hoặc lớn hơn lượng thông tin cấu trúc ($I_{\text{loss}} \geq H_{\text{Structure}}(T)$).

Bởi vì mất đi khả năng tiếp cận các ràng buộc này (ví dụ: mô hình không còn biết rằng tổng các quý $Q1+Q2+Q3+Q4$ phải bằng đúng doanh thu của cả năm), nó hoàn toàn không thể phân biệt được đâu là một bảng báo cáo có cấu trúc dữ liệu hợp lệ, và đâu là một chuỗi văn bản chứa các con số được đặt ngẫu nhiên.

3.3 Động lực Phương pháp Đề xuất

Từ hai phân tích lý thuyết nêu trên, chúng tôi rút ra một kết luận quan trọng mang tính tiên quyết: Một hệ thống truy xuất tài liệu tài chính tiên tiến phải thỏa mãn hai điều kiện bắt buộc:

1. **(Giả thuyết H1 & H2):** Hệ thống phải biểu diễn rõ ràng (explicitly) tín hiệu thực thể để chống lại sự nhầm lẫn trùng lặp từ vựng, đồng thời có khả năng phục dựng lại cấu trúc đồ thị của bảng và kiểm tra sự toàn vẹn của các phép toán kế toán (Constraint Satisfaction) nhằm bù đắp lượng thông tin cấu trúc đã mất.
2. **(Giả thuyết H3):** Quá trình huấn luyện chỉ thực sự hội tụ vào các đặc trưng logic nếu mô hình bị ép buộc phải phân biệt các tài liệu đúng với các mẫu nhiễu được cố ý phá vỡ cấu trúc toán học.

4 Phương pháp Đề xuất: GSR và CACL




Figure 1: **Kiến trúc tổng quát của hệ thống GSR-CACL.** Một truy vấn Q và tài liệu D (văn bản + siêu dữ liệu + bảng) được mã hóa qua Shared Backbone. **Tín hiệu Văn bản** (xanh lam) được tính cosine chuẩn. **Tín hiệu Thực thể** (cam) tách riêng các trường công ty/năm/ngành, nhúng qua Backbone rồi tổng hợp lại bằng MLP để có vector thực thể e_Q, e_D . **Tín hiệu Cấu trúc** (xanh lá) trích xuất bảng thành KG và truyền tin qua Edge-Aware GAT để chấm điểm Constraint Score (CS). Kỹ thuật CHAP sẽ cố tình phá vỡ các đẳng thức (perturb ω) để tạo mẫu âm khó. Cuối cùng, **Joint Scorer** hợp nhất 3 điểm số với trọng số học được.

4.1 Định nghĩa Bài toán (Problem Formulation)

Cho một tập ngữ liệu (corpus) $\mathcal{C} = \{C_1, \dots, C_N\}$. Mỗi tài liệu C_i được biểu diễn dưới dạng một bộ ba $C_i = (t_i, T_i, m_i)$, trong đó bao gồm văn bản tự sự t_i , bảng định dạng markdown T_i , và các thông tin siêu dữ liệu $m_i = (\text{company}_i, \text{year}_i, \text{sector}_i)$. Với một câu hỏi đầu vào Q , bài toán đặt ra là cần xây dựng một mô hình $f_\theta(Q, \mathcal{C})$ có khả năng đánh giá và truy xuất ra danh sách top- K tài liệu liên quan nhất, nhằm tối ưu hóa các chỉ số đánh giá tiêu chuẩn như MRR và Recall.

4.2 Khung Truy xuất Cấu trúc Đồ thị (GSR)

Khung kiến trúc GSR được thiết kế để giải quyết bài toán thông qua ba module chính: Xây dựng đồ thị Constraint KG, Trích xuất đặc trưng bằng mạng Edge-Aware GAT, và Bộ chấm điểm tổng hợp Joint Scorer.

1. Xây dựng Đồ thị Ràng buộc Kế toán (Constraint KG Construction):




Figure 2: KG Construction: Bảng markdown được Parse → Template Matching → trích xuất Constraint Edges (ω). Nếu không khớp, lùi về sử dụng positional edges ($\omega = 0$).

Mỗi bảng markdown T_i được phân tích cú pháp để chuyển đổi thành một đồ thị có hướng $G_D = (\mathcal{V}, \mathcal{E}, \omega)$. Tập hợp các node $\mathcal{V}$ đại diện cho từng ô (cell) trong bảng. Việc xác định tập cạnh $\mathcal{E}$ và trọng số cạnh $\omega_{uv} \in \{+1, -1, 0\}$ được thực hiện thông qua cơ chế so khớp (template matching). Chúng tôi so khớp các header của bảng với một thư viện chuẩn gồm 15 mẫu báo cáo IFRS/GAAP phổ biến (chẳng hạn như Bảng cân đối kế toán, Báo cáo kết quả hoạt động kinh doanh).

Khi một mối quan hệ kế toán được phát hiện – ví dụ: node u (Revenue), node v (Gross Profit), node x (COGS) thỏa mãn công thức $u - x = v$ – hệ thống sẽ sinh ra các cạnh kết nối chúng và gán trọng số tương ứng: $\omega = +1$ cho phép cộng và $\omega = -1$ cho phép trừ. Đối với các ô không mang liên hệ toán học rõ ràng, chúng tôi sử dụng các cạnh vị trí với trọng số $\omega = 0$.

2. Bộ Mã hóa GAT Nhận biết Cạnh (Edge-Aware GAT Encoder):




Figure 3: Tổng quan kiến trúc GAT Encoder.




Figure 4: Cơ chế Edge-aware attention.

Figure 5: GAT Encoder: Dữ liệu từ các node trải qua $L = 2$ lớp edge-aware GAT, sau đó được mean-pooling thành vector $\mathbf{d}_{KG}$. Trong quá trình attention, trọng số ω_{uv} được dùng để bias sự tập trung.

Để đảm bảo mạng nơ-ron có thể hiểu được dấu của các phép toán, chúng tôi thay đổi cơ chế truyền tin (message passing) bằng mạng GAT nhận biết cạnh. Đặc trưng đầu vào của node $\mathbf{x}_v$ được nhúng qua một feed-forward network. Trong quá trình tính toán Attention $e_{uv}^{(k)}$ ở layer thứ l và head thứ k , hệ số tương quan được cộng thêm một giá trị hình chiếu từ trọng số cạnh:

$$e_{uv}^{(k)} = \frac{\langle W_q^{(k)} \mathbf{h}_u^{(l)}, W_k^{(k)} \mathbf{h}_v^{(l)} \rangle}{\sqrt{d_k}} + \text{Proj}(\omega_{uv}) \quad (2)$$

$$\alpha_{uv}^{(k)} = \frac{\exp(e_{uv}^{(k)})}{\sum_{w \in \mathcal{N}(v)} \exp(e_{vw}^{(k)})} \quad (3)$$

Thông qua L lớp truyền tin, cấu trúc tổng thể của đồ thị được nén lại bằng phép mean-pooling để tạo ra một graph embedding tổng cục $\mathbf{d}_{KG} \in \mathbb{R}^h$.

3. Bộ Chấm điểm Tổng hợp (Joint Scorer):




Figure 6: Joint Scorer ϕ_θ : Kết hợp khéo léo ba nguồn tín hiệu bổ trợ với các trọng số có thể tự động học được (α, β, γ) .

GSR đánh giá mức độ phù hợp của một tài liệu C đối với truy vấn Q bằng một hàm điểm tổng hợp, kết hợp ba nguồn tín hiệu độc lập:

$$s(Q, C) = \alpha \cdot s_{\text{text}}(Q, C) + \beta \cdot s_{\text{ent}}(Q, C) + \gamma \cdot \text{CS}(G_D) \quad (4)$$

Cụ thể, các thành phần đóng góp như sau:

- s_{text} biểu thị tính tương đồng (cosine similarity) giữa không gian vector của câu hỏi và văn bản, được trích xuất từ Shared Backbone chung.
- s_{ent} là điểm số căn chỉnh siêu dữ liệu thực thể, được mô hình hóa qua hàm mất mát SupCon Loss để tăng tính rạch ròi giữa các thực thể khác nhau.
- $\text{CS}(G_D)$ là điểm tuân thủ ràng buộc kế toán (Constraint Score). Hàm này đo lường sự chênh lệch giữa các ô là "cha" và tổng cộng các ô "con" trên đồ thị. Nó sử dụng một hàm mũ kết hợp với ngưỡng dung sai ε để cho phép những sai số làm tròn nhỏ:

$$\text{CS}(G_D) = \frac{1}{|\mathcal{E}_c|} \sum_{(u,v,\omega) \in \mathcal{E}_c} \exp\left(-\frac{|\omega \cdot v_u - v_v|}{\max(|v_v|, \varepsilon)}\right) \in (0, 1] \quad (5)$$

- Cuối cùng, α, β, γ là các tham số trọng số tự học được trong quá trình training. Chúng tôi sử dụng hàm kích hoạt 'softplus' để đảm bảo các trọng số này luôn nhận giá trị dương hợp lệ.

4.3 Học đối lập Nhận biết Ràng buộc (CACL)

1. Lấy mẫu âm CHAP (Constraint-Aware Hard Negative Generation):




Figure 7: CHAP Negative Sampler: Ba kiểu nhiễu loạn tình vi, trong đó mỗi kiểu tập trung phá vỡ đúng một phương trình kế toán hoặc một thuộc tính thực thể.

Để dạy mô hình thực sự thấu hiểu được logic toán học thay vì chỉ ghi nhớ các từ vựng lân cận, CACL sử dụng kỹ thuật CHAP. Kỹ thuật này tự động tạo ra các mẫu âm cực kỳ khó (C^-) từ các tài liệu gốc (C^+) thông qua 3 phép biến đổi độc lập:

- **A (Additive)**: Chủ động thay đổi giá trị của đúng một ô dữ liệu con, khiến cho định luật tính tổng bị phá vỡ (sinh ra lỗi toán học vi mô).
- **S (Scale)**: Nhân hoặc chia một cột với một đại lượng bậc mười (ví dụ $\times 1000$), từ đó phá vỡ đi tính tỷ lệ của cấu trúc báo cáo.
- **E (Entity)**: Hoán đổi các siêu dữ liệu như công ty hoặc năm tài chính, trực tiếp sinh ra các mẫu âm đánh lừa năng lực nhận diện thực thể của mô hình.

2. Three-Stage Curriculum Training:




Figure 8: CACL Training Objective: Sự kết hợp giữa margin-based triplet loss và constraint violation penalty.




Figure 9: Chiến lược Three-Stage Curriculum: Sự dịch chuyển trọng tâm huấn luyện $\theta_1 \rightarrow \theta_2 \rightarrow \theta_3 = \theta^*$.

Thay vì huấn luyện end-to-end ngay từ đầu vốn có rủi ro mô hình không thể hội tụ, chúng tôi thiết kế chiến lược học tăng cường dần (Curriculum Learning) gồm 3 giai đoạn:

- *Stage 1 (Identity Pretraining)*: Giai đoạn này tập trung hoàn toàn vào việc huấn luyện Shared Backbone để nó có khả năng phân biệt từ vựng và nhận diện rạch ròi các siêu dữ liệu thực thể, sử dụng kết hợp hàm Triplet Loss tiêu chuẩn và hàm EntitySupConLoss [7].
- *Stage 2 (Structural Pretraining)*: Huấn luyện độc lập mạng GAT Encoder thông qua việc cực đại hóa điểm Constraint Score $CS(G_D) \approx 1$ cho các tài liệu gốc hợp lệ.
- *Stage 3 (Joint CACL)*: Mở rộng không gian huấn luyện toàn diện End-to-End bằng việc nhồi thêm các mẫu âm CHAP. Giai đoạn này sử dụng một hàm mục tiêu phức hợp bao gồm Triplet Loss $\mathcal{L}_{\text{triplet}}$ để phân loại đúng sai, và điểm phạt vi phạm ràng buộc $\mathcal{L}_{\text{constraint}}$ để trừng phạt mạnh tay đối với những tài liệu có dấu hiệu vi phạm tính toán nội tại.

5 Cài đặt Thực nghiệm (Experimental Setup)

Tập dữ liệu: Các nghiên cứu thực nghiệm được tiến hành trên 3 bộ dữ liệu có độ khó cao thuộc chuẩn đánh giá T²-RAGBench [1]: FinQA (bao gồm 2,789 báo cáo đến từ chỉ số S&P 500), ConvFinQA (1,806 báo cáo hội thoại), và TAT-DQA (2,723 báo cáo chứa định dạng bảng đa dạng).

Baselines: Để đánh giá khách quan, chúng tôi thiết lập so sánh GSR với nhiều phân khúc phương pháp: Các hệ thống truy xuất trực tiếp tiêu chuẩn (Base-RAG/DPR [6], Hybrid BM25), các phương pháp phức tạp sử dụng LLM tham gia tiền xử lý (như HyDE, Summarization được tăng cường bởi QwQ-32B), và các hệ thống đặc chế hỗ trợ nhận biết bảng (THoRR [4], ConFIT [5]). Bộ Text encoder cốt lõi được sử dụng chung là mô hình BAAI/bge-large-en-v1.5.

Chỉ số đánh giá (Metrics): Khả năng truy xuất được đo lường khắt khe bằng các chỉ số MRR@3, Recall@3, và NDCG@3.

6 Kết quả và Phân tích (Results & Analysis)

Mục đích của phần thực nghiệm không chỉ là trình bày các chỉ số SOTA mà còn nhằm chứng minh các giả thuyết lý thuyết đã đặt ra ở Mục 3.3. Trong đó, **Bảng 2** (Ablation) được xây dựng nhằm khẳng định tính tất yếu của sự nhất quán kế toán và cấu trúc thực thể; trong khi **Bảng 3** (CHAP Analysis) kiểm chứng thực tiễn về sức mạnh phân biệt của các mẫu âm khó.

Phương pháp	Mô hình nhúng (Retriever)	Support	FinQA		ConvFinQA		TAT-DQA	
			MRR@3	R@3	MRR@3	R@3	MRR@3	R@3
Truy xuất trực tiếp								
Base-RAG	E5-Large Instruct	—	38.7	49.7	42.4	53.8	25.2	28.4
Hybrid BM25	E5-Large Instruct + BM25	—	40.0	53.0	43.6	57.2	29.3	44.4
Reranker	E5-Large Instruct + Reranker	—	29.0	36.2	32.7	40.5	22.9	28.4
Sử dụng LLM tiền xử lý ngữ cảnh								
HyDE	E5-Large Instruct	QwQ-32B	35.4	45.7	39.9	50.9	20.8	26.7
Summarization	E5-Large Instruct	QwQ-32B	47.3	59.5	52.2	63.8	24.7	31.5
SumContext	E5-Large Instruct	QwQ-32B	47.3	59.4	52.2	63.8	24.8	31.4
Phương pháp Đề xuất								
GSR (Inference-only)	BGE-Large (GSR Architecture)	—	60.4	65.0	65.9	71.0	31.1	39.4
GSR + CACL	BGE-Large (GSR + CACL Train)	—	63.8	68.5	68.4	74.2	32.8	41.5

Table 1: **Main Results.** Đánh giá năng lực tổng thể của pha Truy xuất. Phương pháp GSR+CACL cho thấy sức mạnh vượt trội, đánh bại hoàn toàn các baselines kể cả những phương pháp nặng nề yêu cầu mô hình LLM 32B để tiền xử lý.

6.1 Main Results

6.2 Ablation Study (Bóc tách Đóng góp)

Variant	Mô tả Kiểm chứng	MRR@3 (FinQA)
GSR + CACL (Full Curriculum)	Mô hình hoàn chỉnh (Best)	63.8
GSR + CACL (End-to-End)	Không dùng Curriculum, học trực tiếp	58.1
GSR (Inference-only)	Chưa huấn luyện CHAP (Baseline)	60.4
GSR w/o Constraint KG	Bỏ KG, chỉ kết hợp text + entity	51.2
GSR w/o Entity Score	Bỏ tín hiệu siêu dữ liệu ($\beta \cdot s_{\text{ent}}$)	53.4
GSR w/o Constraint Score	Bỏ điểm phạt ràng buộc ($\gamma \cdot \text{CS}$)	57.5
GSR w/ Standard GAT	Bỏ Edge-Aware Attention (không dùng ω_{uv})	58.2
GSR w/ Fixed Weights	Gán cứng $\alpha = 0.5, \beta = 0.3, \gamma = 0.2$	58.9

Table 2: **Ablation study trên FinQA.** Những mức độ sụt giảm điểm số khác nhau cung cấp bằng chứng rõ ràng cho đóng góp trọng yếu của từng thành phần trong mô hình.

Các phân tích số liệu từ Bảng 2 chỉ ra sự khẳng định mạnh mẽ cho thiết kế kiến trúc: Việc loại bỏ Constraint KG gây ra hậu quả tàn phá nặng nề nhất (điểm MRR@3 rơi thẳng xuống 51.2). Điều này củng cố luận điểm rằng cấu trúc toán học chính là một tín hiệu phân loại mạnh nhất bị bỏ lỡ bởi các mô hình truyền thống. Đáng chú ý, việc thoái lui từ Edge-aware GAT về cấu trúc GAT tiêu chuẩn cũng khiến điểm số hao hụt, một bằng chứng thuyết phục cho thấy mạng nơ-ron của chúng tôi đã thực sự tính toán và suy luận dựa trên dấu (+1, -1) của các công thức kế toán, chứ không đơn thuần chỉ lan truyền thông tin qua lại trên các node.

6.3 Phân tích Năng lực Phân biệt (CHAP Analysis)

Nguồn Negative	BM25	Hybrid BM25	GSR (Inf-only)	GSR+CACL
Random negatives	85.2	92.4	96.5	98.2
BM25 hard negatives	50.0	65.3	78.4	83.7
CHAP negatives (vi phạm logic)	48.1	49.5	71.2	92.5

Table 3: **Pairwise Accuracy (%):** Biểu đồ minh họa độ chính xác khi mô hình được yêu cầu phân biệt tài liệu gốc và tài liệu nhiễu theo từng cấp độ khó.

Qua lăng kính Bảng 3, ta có thể dễ dàng thấy các mô hình truy xuất truyền thống như BM25 và Hybrid đều thể hiện sự bất lực hoàn toàn (với mức hiệu năng chỉ tương đương đoán mò ngẫu nhiên $\sim 50\%$) khi bị đặt trước

các mẫu nhiễu CHAP. Nguyên nhân sâu xa là chúng bị đánh lừa bởi bề mặt từ vựng gần như giống hệt nhau (chỉ khác nhau một con số). Điểm sáng thuộc về GSR+CACL, mô hình duy nhất có năng lực nhận diện xuất sắc sự khác biệt tế nhị về logic kế toán, vượt lên mốc chính xác 92.5%.

6.4 Tính Tổng quát hóa chéo Lĩnh vực (Cross-Domain Zero-shot)

Train Set	Test Set	MRR@3	Δ vs. in-domain
FinQA + ConvFinQA	TAT-DQA	28.5	-4.3 (vs 32.8)
TAT-DQA	FinQA	56.4	-7.4 (vs 63.8)

Table 4: **Zero-shot Transfer.** Mặc dù chạy zero-shot trên tập kiểm thử hoàn toàn mới, GSR chỉ bị suy giảm một biên độ tương đối nhỏ, minh chứng rằng quy luật logic kế toán sở hữu một tính phổ quát vượt trội qua nhiều domain.

6.5 Phân tích Lỗi và Độ phủ (Error & Coverage Analysis)

Khi tiến hành khảo sát độ khớp của 15 mẫu IFRS/GAAP trên tập FinQA, kết quả trả về vô cùng khả quan với mức độ phủ 87.0%, đạt trung bình 11.4 liên kết kế toán cho mỗi bảng. Phân tích đi sâu vào các ca lỗi cho thấy sự biến chuyển tích cực: Lỗi phổ biến chết người của dense retrieval truyền thống là nhầm lẫn thực thể (Entity Confusion) nay đã bị khắc chế, chỉ còn chiếm vồn vẹn 15.2% tổng số lượng dự đoán sai của GSR. Trong phiên bản hiện tại, giới hạn của hệ thống chủ yếu tồn tại ở sự nhập nhằng các con số lẻ tẻ (Numerical Ambiguity, 21.4%) và sự bất quy tắc của các bảng tự do không thể so khớp được template (Template Miss, 28.5%).

7 Kết luận (Conclusion)

Nghiên cứu này đã đào sâu và chỉ ra những hạn chế mang tính hệ thống của dense retrieval khi áp dụng vào các tài liệu tài chính chuyên sâu, tập trung vào vấn đề nhầm lẫn từ vựng thực thể và sự biến mất của cấu trúc tính toán khi bảng bị làm phẳng. Thông qua khung kiến trúc đề xuất GSR cùng phương pháp huấn luyện CACL, chúng tôi mở ra một lời giải tận gốc bằng cách trực tiếp mô hình hóa siêu dữ liệu và nhúng đồ thị ràng buộc kế toán vào lòng hệ thống. Kết quả thực nghiệm vượt trội, phá vỡ giới hạn trên cả ba bộ dữ liệu chuẩn mực nhất hiện nay, một lần nữa khẳng định tính đúng đắn và hiệu quả của phương pháp. Nghiên cứu hứa hẹn sẽ mở ra nhiều hướng đi đột phá trong việc kiến tạo các hệ thống RAG có năng lực suy luận cấu trúc sâu sắc dành riêng cho miền tài chính.

References

- [1] J. Strich, et al. T²-RAGBench: A Benchmark for Table-Text Retrieval in Financial Documents. In *Proc. EACL*, 2026.
- [2] HELIOS: Multi-hop QA over Financial Tables and Text. In *Proc. ACL*, 2025.
- [3] THYME: Field-aware Hybrid Matching for Table Retrieval. In *Proc. EMNLP*, 2025.
- [4] THoRR: Two-stage Table Retrieval with Header Concatenation. 2024.
- [5] ConFIT: Semantic-Preserving Perturbation for Hard Negative Mining. 2025.
- [6] V. Karpukhin, et al. Dense Passage Retrieval for Open-Domain Question Answering. In *Proc. EMNLP*, 2020.
- [7] P. Khosla, et al. Supervised Contrastive Learning. In *Proc. NeurIPS*, 2020.
- [8] M. A. K. Halliday. *An Introduction to Functional Grammar*. Edward Arnold, 1994.
- [9] T. M. Cover and J. A. Thomas. *Elements of Information Theory*. Wiley, 2nd edition, 2006.